

## Entrega ejercicio Temas 2 y 3

Jose Antonio Lorencio Abril

Curso 21/22

**Ejercicio 1.** Sea  $(X_1, \dots, X_n)$  una m.a.s. de una población  $X \sim N(\mu, \sigma^2)$ . Demostrar que  $\bar{X}$  y  $(X_1 - \bar{X}, \dots, X_n - \bar{X})$  son independientes.

Demostrar a partir de este resultado que  $\bar{X}$  y  $S^2$  son independientes.

Primero, notamos que, para todo  $j = 1, \dots, n$ , es

$$\bar{X} - X_j = \sum_{i=1}^n \frac{X_i}{n} - X_j = \frac{X_1 + \dots + X_{j-1} + X_{j+1} + \dots + X_n}{n} - \frac{n-1}{n} X_j$$

donde el primero de los sumandos es  $N\left(\frac{n-1}{n}\mu, \frac{n-1}{n^2}\sigma^2\right)$  y el segundo es  $N\left(\frac{n-1}{n}\mu, \left(\frac{n-1}{n}\right)^2\sigma^2\right)$ . Por tanto,

$$\bar{X} - X_j \sim N\left(0, \left(\frac{n-1}{n^2} + \frac{(n-1)^2}{n^2}\right)\sigma^2\right) = N\left(0, \frac{n-1}{n}\sigma^2\right)$$

para todo  $j = 1, \dots, n$ .

Por otro lado

$$\begin{aligned} \text{Cov}(X_j - \bar{X}, \bar{X}) &= \text{Cov}(X_j, \bar{X}) - \text{Cov}(\bar{X}, \bar{X}) = E(X_j \bar{X}) - E(X_j)E(\bar{X}) - \text{Var}(\bar{X}) = \\ &= E\left(X_j \frac{1}{n} \sum_{i=1}^n X_i\right) - \mu^2 - \frac{\sigma^2}{n} = \frac{1}{n} \sum_{i=1}^n E(X_i X_j) - \mu^2 - \frac{\sigma^2}{n} = \frac{1}{n} \sum_{i \neq j} E(X_i)E(X_j) + \frac{1}{n} E(X_j^2) - \mu^2 - \frac{\sigma^2}{n} = \\ &= \frac{(n-1)\mu^2 + \text{Var}(X_j^2) + E(X_j)^2 - n\mu^2 - \sigma^2}{n} = \frac{-\mu^2 + \sigma^2 + \mu^2 - \sigma^2}{n} = 0 \end{aligned}$$

por lo tanto, tenemos que  $(\bar{X}, X_1 - \bar{X}, \dots, X_n - \bar{X})$  es una distribución normal multidimensional de la forma

$$N\left((\mu, 0, 0, \dots, 0), \begin{pmatrix} \frac{\sigma^2}{n} & 0 & \dots & 0 \\ 0 & & & \\ \vdots & & \Sigma & \\ 0 & & & \end{pmatrix}\right)$$

para alguna matriz de covarianzas  $\Sigma$ , que no necesitamos determinar.

Por tanto, dado que en la normal multivariante, la incorrelación implica independencia, tenemos que las variables aleatorias  $\bar{X}$  y  $(X_1 - \bar{X}, \dots, X_n - \bar{X})$  son independientes, como queríamos ver.

Ahora, para la última parte, notamos que la función

$$\begin{aligned} g: \mathbb{R}^n &\rightarrow \mathbb{R} \\ (x_1, \dots, x_n) &\mapsto \sum x_{in}^2 \end{aligned}$$

es medible Borel, y que

$$S^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n} = g(X_1 - \bar{X}, \dots, X_n - \bar{X})$$

por lo que  $S^2$  es una transformación de  $(X_1 - \bar{X}, \dots, X_n - \bar{X})$  mediante una función medible Borel, y como esta variable aleatoria es independiente de  $\bar{X}$ , entonces también lo es  $S^2$ .

**Ejercicio 2.** Sea  $X$  una variable aleatoria con distribución de Poisson, de parámetro  $\lambda$  ( $X \sim P(\lambda)$ ) y sea  $(X_1, \dots, X_n)$  una m.a.s. de  $X$ .

a) Obtener las condiciones de regularidad de Cramer-Rao para el estadístico  $\bar{X}$

i)  $\Psi = \text{sop}(\mathbf{X}) = \{0, 1, \dots\}^n$  independiente de  $\lambda$

ii) Calculamos la función de verosimilitud

$$L(\mathbf{x}, \lambda) = \prod_1^n p(x_i, \lambda) = \prod_1^n \frac{e^{-\lambda} \lambda^{x_i}}{x_i!} = \frac{e^{-n\lambda} \lambda^{\sum x_i}}{\prod x_i!}$$

y esta función es claramente derivable respecto de  $\lambda, \forall \lambda > 0, \forall \mathbf{x} \in \text{sop}(\mathbf{X})$ , pues es el producto de una exponencial por una potenciación.

iii) Primero, definamos  $Y = \sum_1^n X_i$ , de forma que

$$\varphi_Y(t) = \prod_1^n \varphi_{X_i}(t) = \prod_1^n e^{\lambda(e^{it}-1)} = e^{n\lambda(e^{it}-1)}$$

y entonces  $Y \sim P(n\lambda)$ , por lo tanto,  $\bar{X} = \frac{Y}{n} \sim P(\lambda)$ . Por tanto, el problema se simplifica y podemos trabajar con la función puntual de probabilidad de la Poisson, en lugar de con la de verosimilitud. Así, tenemos

$$E[\bar{X}] = \sum_0^\infty i \cdot p_{\bar{X}}(i, \lambda) = \sum_0^\infty i \frac{e^{-\lambda} \lambda^i}{i!}$$

y para que  $\sum_n g_n(x)$  sea derivable bajo el signo de la serie, basta que  $\sum_n g'_n(x)$  converja uniformemente. Ahora bien, la derivada del interior es

$$\frac{\partial}{\partial \lambda} g_i(\lambda) = i \frac{e^{-\lambda} \lambda^i}{i!} + i \frac{e^{-\lambda} i \lambda^{i-1}}{i!} = -i \frac{e^{-\lambda} \lambda^i}{i!} + i^2 \frac{e^{-\lambda} \lambda^{i-1}}{i!}$$

y entonces

$$\sum_0^\infty \frac{\partial}{\partial \lambda} g_i(\lambda) = \sum_0^\infty -i p_{\bar{X}}(i, \lambda) + \frac{i^2}{\lambda} p_{\bar{X}}(i, \lambda) = -E[\bar{X}] + \frac{1}{\lambda} E[\bar{X}^2]$$

con la convergencia uniforme pues

$$\sum_{i=\lambda}^\infty \left| \frac{\partial}{\partial \lambda} g_i(\lambda) \right| = \sum_{i=\lambda}^\infty \left| i \frac{e^{-\lambda} \lambda^{i-1}}{i!} [-\lambda + i] \right| \leq \sum_{i=\lambda}^\infty \left| i^2 \frac{e^{-\lambda} \lambda^{i-1}}{i!} \right| = e^{-\lambda} \sum_{i=\lambda}^\infty \left| i \frac{\lambda^{i-1}}{(i-1)!} \right| \stackrel{K_\lambda > \lambda}{\leq} e^{-\lambda} \sum_{i=\lambda}^\infty \frac{i K_\lambda^{i-1}}{(i-1)!}$$

Ahora bien:

$$\begin{aligned} \sum_{i=2}^\infty \frac{i K^{i-1}}{(i-1)!} &= \sum_{i=1}^\infty \frac{(i+1) K^i}{i!} = \sum_{i=1}^\infty \frac{K^i}{(i-1)!} + \sum_{i=1}^\infty \frac{K^i}{i!} = \\ &= K \sum_{i=1}^\infty \frac{K^{i-1}}{(i-1)!} + e^K - 1 = K \sum_{i=0}^\infty \frac{K^i}{i!} + e^K - 1 = K e^K + e^K - 1 \end{aligned}$$

entonces la serie anterior converge independientemente del  $K_\lambda$  que tomemos, pues aunque empezamos en  $i = \lambda$ , la cantidad finita de términos iniciales no nos importa. El criterio  $M$  de Weierstrass nos proporciona la convergencia uniforme de las derivadas buscadas (Suponiendo que el dominio de  $\lambda$  está acotado, para poder tomar un  $K$  que acote a todos los  $\lambda$  buscados.

Esto es razonable, de todas formas, ya que la cota podemos tomarla arbitrariamente alta y, en consecuencia, nos servirá para cualquier  $\lambda$ ) y tenemos la derivabilidad bajo el signo de la serie de  $E[\bar{X}]$ .

Falta ver que  $\sum \dots \sum_{\Psi} L(\mathbf{x}, \lambda)$  es derivable bajo el signo de la serie, pero para esto basta ver que  $\sum_x p(x, \lambda) = \sum_i \frac{e^{-\lambda} \lambda^i}{i!}$  lo es, por el siguiente criterio de convergencia:

Si  $f_n \xrightarrow{\text{unif}} f$  y  $h_n \xrightarrow{\text{unif}} h$  y existen constantes con  $|f_n(x)| \leq M_1, |h_n(x)| \leq M_2, \forall x$ , entonces  $f_n h_n \xrightarrow{\text{unif}} fh$ .

Para verlo, calculamos

$$\frac{\partial}{\partial \lambda} p_i(\lambda) = \frac{-e^{-\lambda} \lambda^i + e^{-\lambda} i \lambda^{i-1}}{i!} = \frac{e^{-\lambda} \lambda^{i-1}}{i!} [-\lambda + i]$$

entonces, razonando como antes, obtenemos

$$\left| \frac{\partial}{\partial \lambda} g_i(\lambda) \right| \leq \frac{i K_{\lambda}^{i-1}}{i!} = \frac{K_{\lambda}^{i-1}}{(i-1)!}$$

Esta serie da  $e^{K_{\lambda}}$ . Así, la serie de las derivadas converge uniformemente por el criterio M de Weierstrass (sobre acotados en  $\lambda$ ).

Ahora aplicamos el criterio mencionado tomando  $f_n = h_n = \sum_{i=1}^n \frac{\partial}{\partial \lambda} p_i(\lambda)$  con la cota  $e^K$ . Haciendo esto  $n$  veces obtenemos la convergencia uniforme de la derivada de la función de verosimilitud (sobre acotados en  $\lambda$ ).

iv)

$$\begin{aligned} E \left[ \left( \frac{\partial \log L(\mathbf{X}, \lambda)}{\partial \lambda} \right)^2 \right] &< \infty \\ \log L(\mathbf{X}, \lambda) &= -n\lambda + \sum x_i \log \lambda - \sum \log x_i! \\ \frac{\partial}{\partial \lambda} L(\mathbf{x}, \lambda) &= -n + \frac{\sum x_i}{\lambda} \\ \left( \frac{\partial}{\partial \lambda} L(\mathbf{x}, \lambda) \right)^2 &= n^2 + \frac{(\sum x_i)^2}{\lambda^2} - 2 \frac{n}{\lambda} \sum x_i = n^2 + \frac{\sum x_i^2 + \sum_{i \neq j} x_i x_j}{\lambda^2} - 2 \frac{n}{\lambda} \sum x_i \\ E \left[ \left( \frac{\partial \log L(\mathbf{X}, \lambda)}{\partial \lambda} \right)^2 \right] &= n^2 + \frac{1}{\lambda^2} \sum E[X^2] + \frac{1}{\lambda^2} \sum_{i \neq j} E[X_i X_j] - 2 \frac{n}{\lambda} \sum E[X] = \\ &= n^2 + \frac{\sum (Var[X] + E[X]^2)}{\lambda^2} + \frac{\sum_{i \neq j} E[X_i] E[X_j]}{\lambda^2} - \frac{2n \cdot n\lambda}{\lambda} = \\ &= \frac{n\lambda + n\lambda^2 + (n^2 - n)\lambda^2 - n^2\lambda^2}{\lambda^2} = \frac{n\lambda + \cancel{n\lambda^2} + \cancel{n^2\lambda^2} - \cancel{n\lambda^2} - \cancel{n^2\lambda^2}}{\lambda^2} = \frac{n}{\lambda} \end{aligned}$$

que es finito.

b) Obtener la cantidad de información de Fisher

Ya lo hemos hecho, pero lo hacemos de otra forma:

$$\log p(x, \lambda) = -\lambda + x \log \lambda - \log x!$$

$$\frac{\partial}{\partial \lambda} \log p(x, \lambda) = -1 + \frac{x}{\lambda}$$

$$\begin{aligned}
E \left[ \left( \frac{\partial}{\partial \lambda} \log p(X, \lambda) \right)^2 \right] &= E \left[ 1 + \frac{X^2}{\lambda^2} - 2 \frac{X}{\lambda} \right] = 1 + \frac{1}{\lambda^2} E[X^2] - \frac{2}{\lambda} E[X] = \\
&= 1 + \frac{\text{Var}[X] + E[X]^2}{\lambda^2} - \frac{2}{\lambda} \lambda = \frac{\lambda + \lambda^2}{\lambda^2} - 1 = \frac{\lambda + \lambda^2 - \lambda^2}{\lambda^2} = \frac{1}{\lambda}
\end{aligned}$$

Y, como  $X$  verifica las condiciones de regularidad de Cramer-Rao, entonces es

$$I_n(\lambda) = nE \left[ \left( \frac{\partial}{\partial \lambda} \log p(X, \lambda) \right)^2 \right] = \frac{n}{\lambda}$$

c) Estudiar si el estadístico  $\bar{X}$  es EIMV de  $\lambda$

Primero, como  $E[\bar{X}] = E[X] = \lambda$ , sabemos que es un estimador insesgado. Pero, además, como

$$\text{Var}[\bar{X}] = \frac{\text{Var}[X]}{n} = \frac{\lambda}{n} = \frac{1}{I_n(\lambda)}$$

Y entonces el estimador alcanza la cota de Cramer-Rao, por lo que es mínima varianza. En conclusión,  $\bar{X}$  es EIMV de  $\lambda$ .

**Ejercicio 3.** Sea  $P = X (X^T X)^{-1} X^T$ , entonces se verifica:

1.  $P, I_n - P$  son simétricas e idempotentes
2.  $r(I_n - P) = \text{tr}(I_n - P) = n - k$
3.  $(I_n - P)X = 0$

Para ver 1., primero vamos a ver que si  $A$  es invertible, entonces  $A^{T^{-1}} = A^{-1T}$ :

$$A^T A^{-1T} = (A^{-1} A)^T = I^T = I$$

$$A^{-1T} A^T = (A A^{-1})^T = I^T = I$$

como afirmábamos. Ahora:

$$P^T = \left( X (X^T X)^{-1} X^T \right)^T = X^{TT} (X^T X)^{-1T} X^T = X (X^T X^{TT})^{-1} X^T = X (X^T X)^{-1} X^T = P$$

por lo que  $P$  es simétrica.

$I_n - P$  es simétrica, por ser suma de simétricas.

Para ver la idempotencia:

$$P^2 = \left( X (X^T X)^{-1} X^T \right) \left( X (X^T X)^{-1} X^T \right) = X \cancel{(X^T X)^{-1} (X^T X)} (X^T X)^{-1} X^T = X (X^T X)^{-1} X^T$$

$$(I_n - P)^2 = I_n^2 - I_n P - P I_n + P^2 = I_n - 2P + P = I_n - P$$

2. Las matrices simétricas son diagonalizables, o sea, si  $A$  es simétrica entonces existe  $Q$  ortogonal con  $A = Q D Q^T$  donde  $D$  es una diagonal de valores propios. Además, las matrices idempotentes tienen todos sus valores propios 0 o 1, puesto que  $(Q D Q^T)^2 = Q D Q^T Q D Q^T = Q D^2 Q^T = A^2 = A = Q D Q^T \implies D^2 = D$  y los valores propios son 0 o 1. Así, si vemos que  $I_n - P$  tiene rango  $n - k$ , tendremos el resultado por la invarianza de la traza. Ahora bien  $I_n = Q I_n Q^T$ , por lo que  $I_n - P = Q (I_n - D) Q^T$  y entonces la traza será  $n - m$ , donde  $m$  es la cantidad de 1 que hay en  $D$ . Por tanto, si vemos que  $P$  tiene traza  $k$ , o equivalentemente que  $P$  tiene rango  $k$ , tendremos el resultado.

$$P = X (X^T X)^{-1} X^T$$

Nótese que  $P \in \mathcal{M}_{n \times n}$  y  $X^T \in \mathcal{M}_{k \times n}$ , veamos que  $\text{Ker}(X^T) = \text{Ker}(P)$  y que esto implica  $r(P) = k$ , como queremos.

$[\text{Ker}(X^T) = \text{Ker}(P)]:$

( $\subset$ ) Si  $X^T a = 0$ , entonces  $P a = X (X^T X)^{-1} X^T a = 0$ .

( $\supset$ ) Si  $P a = 0$ ,  $\implies X^T P a = X^T X \cancel{(X^T X)^{-1} X^T} a = 0$ .

Luego  $\text{Ker}(X^T) = \text{Ker}(P) = K$ .

En general, se tiene que si  $A \in \mathcal{M}_{m \times n}(\mathbb{R})$ , entonces  $n = r(A) + \dim(\text{Ker}(A))$ .

Por tanto, en nuestro caso tenemos

$$n = r(X^T) + \dim(K) = k + \dim(K) \implies \dim(K) = n - k$$

y por otro lado

$$n = r(P) + \dim(K) = r(P) + n - k \implies r(P) = k$$

como queríamos ver.

3.

$$(I_n - P)X = I_n X - X \cancel{(X^T X)^{-1} X^T} X = X - X = 0$$

**Ejercicio 4:** Demostrar que.

$$\sum_{i=1}^n \left( y_i - \sum_{j=1}^k x_{ij} \beta_j \right)^2 = (\mathbf{y} - \mathbf{X} \hat{\beta})^T (\mathbf{y} - \mathbf{X} \hat{\beta}) + (\hat{\beta} - \beta)^T \mathbf{X}^T \mathbf{X} (\hat{\beta} - \beta)$$

Veámoslo, aunque voy a usar la notación  $\mathbf{y} = Y$  y  $\mathbf{X} = X$ , para facilitar la escritura del ejercicio.

$$\sum_{i=1}^n \left( y_i - \sum_{j=1}^k x_{ij} \beta_j \right)^2 = \sum_{i=1}^n \left( y_i^2 - 2y_i \sum_{j=1}^k x_{ij} \beta_j + \left( \sum_{j=1}^k x_{ij} \beta_j \right)^2 \right) = (*)$$

Notemos en este punto que

$$\begin{aligned} \sum_{i=1}^n y_i^2 &= Y^T Y \\ \sum_{i=1}^n y_i \sum_{j=1}^k x_{ij} \beta_j &= \sum_{i=1}^n y_i X_i \beta = Y^T X \beta \\ \sum_{i=1}^n \left( \sum_{j=1}^k x_{ij} \beta_j \right)^2 &= \sum_{i=1}^n (X_i \beta)^2 = (X \beta)^T (X \beta) \end{aligned}$$

Además, dado que  $Y^T X \beta$  es un escalar (matriz de dimensión  $1 \times 1$ ), se tiene que

$$Y^T X \beta = (Y^T X \beta)^T = (X \beta)^T Y \quad (1)$$

por lo que

$$\begin{aligned} (*) &= Y^T Y - 2Y^T X \beta + (X \beta)^T (X \beta) \stackrel{(1)}{=} Y^T Y - Y^T X \beta - (X \beta)^T Y + (X \beta)^T (X \beta) = \\ &= Y^T (Y - X \beta) - (X \beta)^T (Y - X \beta) = (Y^T - (X \beta)^T) (Y - X \beta) = (Y - X \beta)^T (Y - X \beta) = \\ &= (Y - X \hat{\beta} + X \hat{\beta} - X \beta)^T (Y - X \hat{\beta} + X \hat{\beta} - X \beta) = \\ &= (Y - X \hat{\beta})^T (Y - X \hat{\beta}) + (Y - X \hat{\beta})^T (X \hat{\beta} - X \beta) + (X \hat{\beta} - X \beta)^T (Y - X \hat{\beta}) + (X \hat{\beta} - X \beta)^T (X \hat{\beta} - X \beta) = (**) \end{aligned}$$

Aquí tenemos ya el primero término. Además, el último es:

$$(X \hat{\beta} - X \beta)^T (X \hat{\beta} - X \beta) = (X (\hat{\beta} - \beta))^T X (\hat{\beta} - \beta) = (\hat{\beta} - \beta)^T X^T X (\hat{\beta} - \beta)$$

que es el otro sumando buscado. Por lo que solo resta ver que los otros dos sumandos dan 0. Aquí vamos a utilizar que  $Y^T X \beta$  tiene dimensión 1, por lo que coincide con su traspuesta.

$$\begin{aligned} &(Y - X \hat{\beta})^T (X \hat{\beta} - X \beta) + (X \hat{\beta} - X \beta)^T (Y - X \hat{\beta}) = \\ &= Y^T X \hat{\beta} - Y^T X \beta - \hat{\beta}^T X^T X \hat{\beta} + \hat{\beta}^T X^T X \beta + \hat{\beta}^T X^T Y - \hat{\beta}^T X^T X \hat{\beta} - \hat{\beta}^T X^T Y + \beta^T X^T X \hat{\beta} = \\ &= 2Y^T X \hat{\beta} - 2Y^T X \beta - 2\hat{\beta}^T X^T X \hat{\beta} + 2\hat{\beta}^T X^T X \beta = 2(Y^T X \hat{\beta} - Y^T X \beta - \hat{\beta}^T X^T X \hat{\beta} + \hat{\beta}^T X^T X \beta) \end{aligned}$$

Esto dará 0 si, y solo si, da 0 al dividir por 2. Continuamos con esa expresión y usamos que  $\hat{\beta} = (X^T X)^{-1} X^T Y$

$$Y^T X \hat{\beta} - Y^T X \beta - \hat{\beta}^T X^T X \hat{\beta} + \hat{\beta}^T X^T X \beta =$$

$$\begin{aligned}
&= Y^T (X\hat{\beta} - X\beta) - \cancel{Y^T X (X^T X)^{-1} X^T X} (X^T X)^{-1} X^T Y + \cancel{Y^T X (X^T X)^{-1} X^T X} \beta = \\
&= Y^T (X\hat{\beta} - X\beta) - Y^T X\hat{\beta} + Y^T X\beta = 0
\end{aligned}$$

Tal y como queríamos ver, y ahora sabemos que

$$(**) = (\mathbf{y} - \mathbf{X}\hat{\beta})^T (\mathbf{y} - \mathbf{X}\hat{\beta}) + (\hat{\beta} - \beta)^T \mathbf{X}^T \mathbf{X} (\hat{\beta} - \beta)$$

y tenemos el resultado buscado.